UNIVERSITY
OF ARTIFICIAL
INTELLIGENCE

Инструкция по написанию дипломного проекта

Этап № 1. Утверждение темы дипломного проекта

Укажите тему дипломного проекта и дайте небольшой комментарий:
- Предпосылки (почему выбрали именно эту тему?)
- Описание задачи.
- Как видите ее решение
- Какую базу планируете использовать

Источники для выбора темы:

- Стажировка (рабочий проект от заказчика, но со своими наработками).
  - Если стажировка еще идет, то необходимо уведомить Тимлида. Работайте над проектом для фиксации результата Тимлидом. Должна быть активность на стажировке: отчеты, польза проекту.
  - Если стажировка уже завершилась, то обязательное условие для использования темы со стажировки - присутствие на итоговом лендинге с результатами работы по проекту;
  - Использование только открытых данных для дипломного проекта: категорически нельзя использовать датасет со стажировки;
  - Использование только своих наработок: не используйте приложения созданные на стажировке кем-то еще (алгоритмы и идеи брать можно). Должна быть представлена серия экспериментов с итеративным улучшением качества.

- **Свой проект (или рабочий проект под заказ).**

Если у вас уже имеется тема, необходимо согласовать её с куратором. Обращаем внимание на то, что написание итогового проекта - это процесс с фиксацией экспериментов и логики при создании проекта, а не просто предоставление готового решения.

- **Список тем для дипломного проекта.**

Тему можно выбрать из списка готовых (список приложен ссылкой в материалах) или аналогичную.

- **Индивидуальное решение для исследований.**

Выбрать область, которая вам наиболее интересна (например: медицина, беспилотные автомобили, распознавание изображений и т. д.), найти проблемы, которые имеются в этой области, обсудить с куратором, возможно ли решить эту проблему с помощью нейросетей.

Этап № 2. Сбор базы

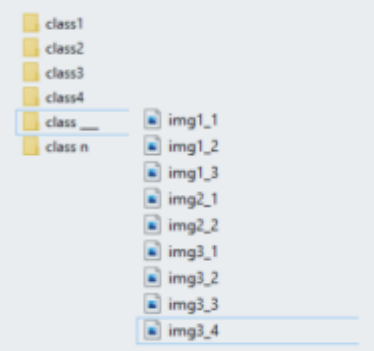
1. Закрытый проект
Если у вас имеется база, предоставленная вашей организацией, и она содержит сведения, не подлежащие разглашению, просьба обезличить данные.

2. Открытые источники, например:
   - Hugging Face — сообщество ИИ, строящее будущее.
   - 10 отличных мест, где можно найти открытые, бесплатные наборы данных [Руководство по 2023 году] (careerfoundry.com)
   - GitHub - awesomedata/awesome-public-datasets: A topic-centric list of HQ open datasets.
   - Наши данные | ПятьЧетвырехайт (fivethirtyeight.com)
   - Реестр открытых данных на AWS (opendata.aws)
   - Общедоступные наборы данных для аналитики Azure — Azure SQL |
   - GitHub - awesomedata/awesome-public-datasets: тематически ориентированный список открытых наборов данных HQ.
3. Парсинг сайтов . Инструкция по парсингу: https://youtu.be/C-kwp3QUCt8
4. Сотрудничество с организациями
5. Сбор базы фрилансерами
6. Вручную

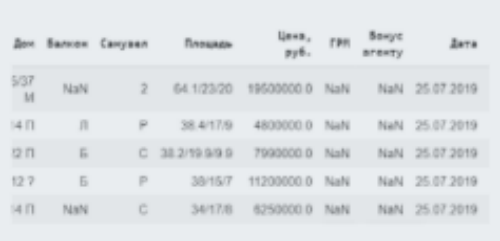
Этап № 3. Парсинг данных

В зависимости от типа задачи:

· **Задача классификации.**
Если стоит задача классификации изображений, то изображения можно сгруппировать по папкам для каждого класса или всё хранить в одной папке, но в названии файла указывать номер класса



· **Задача регрессии**
Данные можно хранить в DataFrame или Excel таблице



Дом	Балкон	Санузел	Площадь	Цена, руб.	ГРН	Бонус агенту	Дата
5/37 М	NaN	2	64.1/23/20	19500000.0	NaN	NaN	25.07.2019
4 П	Л	Р	38.4/17/9	4800000.0	NaN	NaN	25.07.2019
2 П	Б	С	38.2/19.9/9.9	7990000.0	NaN	NaN	25.07.2019
12 7	Б	Р	38/15/7	11200000.0	NaN	NaN	25.07.2019
4 П	NaN	С	34/17/8	6250000.0	NaN	NaN	25.07.2019

· **Сегментация**
Для сегментации каждому реальному изображению должно соответствовать сегментированное изображение (объекты каждого класса разукрашены своим цветом)

· **Object detection**
Каждому реальному изображению должны соответствовать аннотации с координатами рамки объекта.



Этап № 4. Создание прототипа НС и получение первой точности распознавания

Задание сдается в виде отчета (word-документ). Отчет должен содержать:

1. Тема, описание задачи
2. База (без конфиденциальных данных)
3. Параметризация данных
4. Архитектура нейросети
5. Графическое подтверждение (графики обучения, матрицы ошибок, графики автокорреляции, ...)
6. Ноутбук (или .py файл)
7. Выводы
8. План дальнейшей работы

Этап № 5. Создание финальной версии НС

Задание сдается в виде ссылки на папку с ноутбуками и доп. файлами для корректной работы ноутбуков (если потребуется), а так же word-документом из Этапа №4.

Примечание: слово функция – это пере используемый блок кода, так же как и классы и модули. Потому использование слова «Функция» далее так же может относиться как к классу, так и к модулю.

Первый ноутбук финальный *(используем/тестируем готовую модель)* должен соответствовать следующим критериям:

1. User-friendly interface – означает, что незнающему человеку достаточно определить все функции(классы) и в конце запустить «тестовую ячейку», в которой ему можно ввести свои тестовые данные (input, google.colab.files.upload) для проверки, провести всю предобработку, предсказать, сделать постобработку данных и сделать понятный ему вывод из предсказания
2. Весь код должен быть разбит на отдельные части («функции») и иметь одну главную «функцию» запуска остальных для проверки работы модели, которая запускается в последней ячейке – Примеры:
   a. Мы должны загрузить файл – должна быть функция загрузки файла, что принимает путь до файла.
   b. Должна быть очистка данных – отдельная функция, что принимает сырые данные
   c. Должна быть предобработка данных – отдельная функция, что принимает как минимум чистые данные
   d. Должно быть создание «загрузчика» (loader) - отдельная функция, что принимает пред обработанные данные
   e. Получение/создание модели – отдельная функция, что принимает пути до загрузки и флаги (preload->boolean)
   f. И так далее.

3. Если для корректной работы ноутбука(предсказания) требуются файлы подгрузки (модель, веса, тестовые данные), то они должны лежать в одной локации вместе с этим ноутбуком.
4. Во всех «функций», что загружают/сохраняют файлы – пути должны быть параметрами с значением по умолчанием (чтобы функцию можно было запустить без явного указания пути)
5. Каждая «функция» должна быть чистой – она должна использовать внутри себя только те переменные, которые были ей переданы как параметры. Исключение – это использование других «функций» как создание новых данных внутри себя. Но без использования результатов предыдущих функций внутри себя, если эти результаты были получены за пределами текущей функции

Второй ноутбук *(здесь Вы показываете свои эксперименты при создании модели)* должен соответствовать следующим критериям:

1. Выводы в ячейках должны быть воспроизводимыми при повторном запуске (небольшие неточности в модели из-за разных весов инициализации не критично)
2. Если в ноутбуке используются загружаемые данные – они должны лежать рядом(или как минимум их sample(часть)) в локации ноутбука.
3. Весь код должен быть разбит на отдельные части («функции»), чтоб исключить повторений в коде. Комментарии к отдельным частям кода.
4. Все эксперименты должны быть видны т.е не используйте одну ячейку, как поле для экспериментов, а дублируйте их, чтобы проследить некие закономерности, но без «фанатизма» (пример – изменили с 24 нейронов на 25)
5. Графики должны быть видны на разные эксперименты. Если ваша модель генерирует нормализованные данные, то для графиков с временными рядами нужно делать обратную трансформацию.

6. В конце должен быть вывод по всем архитектурам, параметрам, их точностям. Также должна быть выбрана «лучшая» модель в соотношении точность/кол-во параметров.
7. Выводы о том, удалось ли добиться желаемой точности. Если не получилось, то написать обоснование, почему не получилось и какие есть еще способы решения этой проблемы.

Этап № 6 Подготовка презентации для защиты дипломного проекта

Необходимо подготовиться к публичному выступлению (дистанционному или очному) регламентом не более 20 минут. Нужно в свободной форме представить свое исследование, дополнив свой рассказ визуальным сопровождением.

При подготовке презентации старайтесь придерживаться следующих рекомендаций:

1.Слайд с персональной информацией:

- название дипломного проекта
- ФИО участника
- старт обучения
- дата защиты

2.Постановка задачи. На данном слайде требуется описать решаемую в ходе дипломного проекта задачу.
3.Обучающая база (при наличии). Данный слайд должен содержать информацию о собранной базе:

- объем базы
- источник сбора данных
- инструменты для сбора данных

- возникшие трудности при сборе базы (при наличии)

4 .Проектирование архитектур НС. Может включать несколько слайдов, на которых требуется раскрыть все отработанные в ходе дипломного исследования гипотезы. Графики должны быть наглядными, читаемыми и аккуратными. Оси на графиках должны быть подписаны. Заголовки должны быть указаны. Можно оформить в виде таблиц с результатами работы каждой из рассматриваемых гипотез.
5.Финальная настройка нейронных сетей. Может включать несколько слайдов, на которых требуется раскрыть финальную настройку и подбор параметров нейронной сети, показавшей максимальные результаты (или нескольких нейронных сетей).

Описанные слайды являются рекомендациями, которые при необходимости могут быть дополнены собственными данными.

Также старайтесь избегать наличия на слайдах следующих элементов:

- Текстовая информация. Наличие большого объема текста на слайде усложняет восприятие. Поэтому старайтесь использовать графическую информацию (таблицы, графики, диаграммы)
- Большие примеры кода программ. Добавляйте код программ только при острой необходимости. Особенно избегайте в своем выступлении демонстрации ноутбуков и повествования на фоне открытого ноутбука.

Шаблон презентации
https://docs.google.com/presentation/d/1hqippMqa0iTMANDGa7M8JCmxqwbCzx-jw2WVHpYG40g/edit?usp=sharing